

# PENERAPAN TEKNIK DEEP LEARNING DALAM IDENTIFIKASI PENYAKIT DAUN PADI BERDASARKAN EKSTRAKSI FITUR VISUAL CITRA

Revelin Putri Syamjovanka

Program Studi Informatika Universitas Pembangunan “Veteran” Jawa Timur

e-mail : [22081010071@student.upnjatim.ac.id](mailto:22081010071@student.upnjatim.ac.id)<sup>1</sup>

Received: [date]; revised: [date]; accepted: [date] (Times New Roman 11)

**Abstract** — *Disease infections on rice leaves, such as blast, blight, and tungro, can reduce crop productivity and threaten food security. This study develops an image-based rice leaf disease classification model using Convolutional Neural Network (CNN). The dataset, obtained from Kaggle, underwent preprocessing including cropping, resizing to 224×224 pixels, normalization, and data augmentation to address class imbalance, resulting in 16,620 images across three disease classes. The dataset was split into training, validation, and testing sets with an 80%:10%:10% ratio. The CNN architecture includes multiple Conv2D and MaxPooling2D layers, followed by Flatten and Dense layers with softmax activation. The model was trained with varying epochs (25, 50, 75, and 100), achieving the best performance at 75 epochs with 100% training and validation accuracy and 99.94% testing accuracy. Precision, recall, and F1-score reached 1.00 for all classes. These results indicate that the proposed CNN model can classify rice leaf diseases with very high accuracy and has the potential to be implemented as a digital image-based early detection system to support agricultural decision-making.*

**Keywords** — *Image classification, rice leaf diseases, deep learning, Convolutional Neural Network (CNN), plant disease diagnosis.*

**Abstrak** — Penyakit pada daun padi, seperti blast, blight, dan tungro, dapat menurunkan produktivitas tanaman dan mengancam ketahanan pangan. Penelitian ini mengembangkan model klasifikasi penyakit daun padi berbasis citra digital menggunakan Convolutional Neural Network (CNN). Dataset yang digunakan berasal dari platform Kaggle dan melalui preprocessing meliputi cropping, resizing menjadi 224×224 piksel, normalisasi, serta augmentasi untuk menangani class imbalance, menghasilkan 16.620 citra pada tiga kelas penyakit. Dataset dibagi menjadi train, validation, dan test dengan rasio 80%:10%:10%. Arsitektur CNN terdiri dari beberapa lapisan Conv2D, MaxPooling 2D, Flatten, dan Dense dengan aktivasi softmax. Model dilatih dengan variasi epoch 25, 50, 75, dan 100, menghasilkan akurasi terbaik pada 75 epoch dengan 100% pada pelatihan dan validasi, serta 99,94% pada pengujian. Precision, recall, dan F1-score mencapai 1,00 pada seluruh kelas. Hasil ini menunjukkan CNN dapat mengklasifikasikan penyakit daun padi secara sangat akurat dan berpotensi digunakan sebagai sistem deteksi dini berbasis citra digital untuk mendukung keputusan di bidang pertanian.

**Kata Kunci** — *klasifikasi citra, penyakit daun padi, deep learning, convolutional neural network, diagnosis tanaman.*

## I. PENDAHULUAN

Padi (*Oryza sativa L.*) merupakan komoditas pangan utama di Indonesia dan Asia yang menjadi sumber karbohidrat bagi sebagian besar penduduk [1]. Gangguan produksi padi, seperti serangan penyakit daun, dapat menurunkan luas area fotosintesis dan menghambat pengisian bulir, sehingga berdampak langsung pada ketahanan pangan. Penyakit daun yang umum antara lain Blast, Blight, dan Tungro, yang dapat menurunkan hasil hingga puluhan persen jika tidak terdeteksi dan ditangani sejak dini [2].


Identifikasi penyakit daun padi di lapangan umumnya masih dilakukan secara visual oleh petani atau penyuluh, yang bersifat subjektif, membutuhkan keahlian khusus, dan memakan waktu [3]. Perkembangan pengolahan citra digital dan deep learning, khususnya Convolutional Neural Network (CNN), membuka peluang untuk membangun sistem diagnosis penyakit secara otomatis melalui citra daun [4]. CNN terbukti mampu mengekstraksi fitur visual kompleks dari daun tanaman dan menghasilkan akurasi tinggi pada klasifikasi penyakit tanaman, termasuk daun padi [5]. Penelitian ini bertujuan mengembangkan model CNN untuk klasifikasi penyakit daun padi ke dalam tiga kelas yakni blast, blight, dan tungro, menggunakan dataset dari Kaggle [6]. Fokus penelitian mencakup perancangan arsitektur CNN yang efektif, tahapan pengolahan dan pembagian dataset, serta evaluasi performa model menggunakan metrik akurasi, precision, recall, F1-score, dan confusion matrix [7]. Hasil penelitian ini diharapkan dapat menjadi referensi dalam pengembangan sistem deteksi dini penyakit daun padi berbasis citra digital untuk mendukung diagnosis yang cepat dan konsisten [8].

Selain itu, penelitian oleh Aditia Putra Pranjaya dkk [9]. (2024) menggunakan YOLOv5 untuk deteksi penyakit daun padi secara real-time dengan akurasi 93% untuk Narrow Brown Spot, 81% untuk Hawar Daun, dan 91% untuk daun normal. Namun, penelitian ini memiliki kekurangan yang cukup signifikan, yaitu hanya mencakup dua jenis penyakit, sehingga cakupan model sangat terbatas, serta ketergantungan tinggi pada kondisi pencahayaan, yang membuat performa model tidak stabil pada lingkungan lapangan yang bervariasi. Penelitian lain oleh Rahmi

dan Rizal Adi Saputra (2024) menerapkan Naive Bayes dan memperoleh akurasi 76%, dengan presisi tinggi untuk Blast dan Blight tetapi sangat rendah pada Tungro [3]. Kekurangan utama penelitian ini terletak pada minimnya jumlah dan keragaman dataset, parameter model yang tidak dikembangkan secara mendalam, serta tidaknya dilakukan augmentasi data, sehingga kemampuan model dalam mengenali variasi gejala penyakit menjadi lemah.

## II. METODE PENELITIAN


Penelitian ini menerapkan metode eksperimen kuantitatif untuk mengevaluasi kinerja model Convolutional Neural Network (CNN) dalam klasifikasi citra penyakit daun padi. Tahapan penelitian meliputi studi literatur, pengumpulan dan pra-pemrosesan data, pembagian dataset menjadi data latih, validasi, dan uji, perancangan model CNN, serta pelatihan dan pengujian untuk memperoleh evaluasi akurasi dan performa model dapat dilihat Pada Gambar 2.1



**Gambar 2.1. Alur Metodologi Penelitian**


### A. Pengumpulan Data

Dataset yang digunakan dalam penelitian ini diambil dari platform Kaggle, berisi kumpulan citra daun padi dengan kategori penyakit seperti: Blast, Blight dan Tungro dengan jumlah data mentahnya mencapai 500 citra padi terdiri dari tiga kelas penyakit daun tanaman padi, yaitu Blast Daun sejumlah 250 gambar, Blinght daun sejumlah 200 gambar dan Tugro daun sejumlah 80 gambar.



**Gambar 2.2. Visualisasi Total Data Tiap Kelas**

Perlu diketahui bahwa citra-citra mentah pada dataset ini memiliki dimensi yang bervariasi, misalnya 320x240, 1024x768 dan lainnya. Ketidaksamaan dimensi ini terjadi karena proses akuisisi citra dilakukan menggunakan perangkat atau teknik yang berbeda-beda, sehingga menghasilkan variasi ukuran pada citra mentah yang diperoleh. Kondisi tersebut menuntut adanya tahapan preprocessing untuk menyeragamkan ukuran gambar agar dapat digunakan secara optimal pada proses pelatihan model klasifikasi citra berbasis deep learning.




**Gambar 2.3. Sampel Penyakit Daun Padi**

### B. Pre-Prosesing Data

Tahap pra-pemrosesan dilakukan sebelum perancangan model untuk memastikan kualitas citra pada pelatihan. Proses ini meliputi augmentasi dan normalisasi data, serta pembagian dataset menjadi data latih, validasi, dan uji untuk mengevaluasi kemampuan model dalam mengenali pola dan menghasilkan prediksi akurat. Tahap ini menjamin data representatif dan siap digunakan dalam pengembangan model.

#### 1. Normalisasi Data

Tahap pra-pemrosesan dalam penelitian ini mencakup pemotongan (*cropping*) dan penyesuaian ukuran (*resize*) citra agar seluruh dataset memiliki rasio aspek 1:1 serta dimensi seragam. Dataset yang digunakan terdiri dari citra dengan ukuran beragam, antara lain 256x256, 1440x1920, hingga 3081x897 piksel. Dalam penelitian ini dapat dilihat pada Gambar 2.4 dimana menunjukkan sampel hasil proses *cropping* dan *resize* menjadi 224x224 piksel. Hasil ini memperlihatkan konsistensi dimensi dan kualitas citra yang siap digunakan untuk pelatihan model CNN. Untuk menjaga konsistensi dan memenuhi persyaratan input pada model, seluruh citra diproses melalui teknik *cropping* di bagian tengah, dengan panjang sisi mengacu pada dimensi terpendek pada masing-masing citra.



**Gambar 2.4. Sampel Hasil Proses Crop and Resize 224x22**

Normalisasi nilai piksel pada penelitian ini juga untuk menyelaraskan rentang intensitas citra. Nilai piksel awal yang berada dalam rentang 1–255 diubah melalui *rescaling* ke dalam rentang 0–1, sehingga semua citra berada pada skala yang seragam sebelum diproses oleh model.

#### 2. Augmentasi Data

Augmentasi dilakukan menggunakan ImageDataGenerator dari pustaka Keras, dengan teknik yang menjabarkan rotasi acak hingga 30°, pergeseran horizontal dan vertikal sebesar 10%, zoom hingga 20%, shear sebesar 20%, flip horizontal, serta pengisian area kosong menggunakan metode *nearest*.

Faktor augmentasi ditentukan berdasarkan kebutuhan jumlah data pada masing-masing kelas, dengan tujuan mengatasi ketidakseimbangan distribusi data (*class imbalance*). Setiap citra

di augmentasi sesuai kelasnya. Citra pada kelas *blight* di augmentasi sebanyak 25 kali, kelas *blast* sebanyak 28 kali, dan kelas *tungro* sebanyak 69 kali. Proses ini menghasilkan dataset yang lebih besar dan seimbang, seperti ditunjukkan pada Tabel 2.1 Data Citra Pre dan Post Augmentasi.

**Tabel 2.1. Data Citra Pre dan Post Augmentasi**

| Jenis Data               | Jumlah data sebelum | Jumlah data sesudah |
|--------------------------|---------------------|---------------------|
| Data Citra <i>blight</i> | 220                 | 5600                |
| Data Citra <i>blas</i>   | 200                 | 5500                |
| Data Citra <i>tungro</i> | 80                  | 5520                |

### 3. Data Splitting

pembagian dataset (data splitting) pada tahap ini, seluruh citra yang telah diperoleh dari proses augmentasi dimuat dan kemudian dibagi menjadi tiga data dilihat pada tabel 2.2 dimana subset utama, yaitu data latih (training), data validasi (validation), dan data uji (testing). Pembagian dataset dilakukan dengan proporsi 80% untuk data latih, 10% untuk data validasi, dan 10% untuk data uji, sehingga setiap kelas memiliki distribusi yang representatif di setiap subset.

**Tabel 2.2. Jumlah Data Citra Sesudah Split Dataset**

| Subset Kategori | Train (80%) | Val(10%) | Test (10%) | Total |
|-----------------|-------------|----------|------------|-------|
| <i>Blight</i>   | 4480        | 560      | 560        | 5600  |
| <i>Blast</i>    | 4400        | 550      | 550        | 5500  |
| <i>Tungro</i>   | 4416        | 552      | 552        | 5520  |

Hasil pembagian dataset menunjukkan bahwa setiap kelas memiliki distribusi yang seimbang pada masing-masing subset. Data latih mendominasi agar model dapat mempelajari pola secara optimal, sedangkan data validasi dan uji tersedia untuk mengevaluasi performa model secara objektif selama dan setelah pelatihan. Dengan distribusi ini, model memiliki dasar yang representatif untuk klasifikasi penyakit daun padi.

### C. Desain Model CNN

Desain arsitektur CNN pada penelitian ini dibangun menggunakan model *Sequential* yang terdiri atas empat blok lapisan konvolusi dengan kernel berukuran  $3 \times 3$ , masing-masing diikuti oleh fungsi aktivasi *ReLU* dan *MaxPooling2D* berukuran  $2 \times 2$  untuk melakukan ekstraksi fitur secara bertahap dari pola tepi dan tekstur sederhana hingga pola bercak penyakit yang lebih kompleks pada citra daun padi berukuran  $224 \times 224 \times 3$ . Jumlah filter pada tiap lapisan konvolusi ditingkatkan secara progresif, yaitu 32, 64, 128, dan 256, guna memperluas kapasitas representasi fitur tanpa menyebabkan lonjakan jumlah parameter yang tidak terkendali, dan seluruh konfigurasi layer divalidasi melalui perhitungan manual ukuran output dan parameter sehingga konsisten secara matematis. Setelah tahap ekstraksi fitur, keluaran jaringan diratakan menggunakan lapisan Flatten dan dihubungkan ke lapisan Dense dengan fungsi aktivasi softmax untuk menghasilkan prediksi tiga kelas penyakit *blight*, *blast* dan *tungro*, dengan total parameter trainable sebesar 499.011 model kemudian dikompilasi menggunakan *optimizer* Adam dengan laju pembelajaran 0,0001 dan fungsi loss *categorical cross-entropy*, yang dalam eksperimen menunjukkan

kemampuan konvergensi yang baik pada tugas klasifikasi multikelas.

### D. Fungsi Aktivitas

Pada penelitian ini digunakan fungsi aktivasi Rectified Linear Unit (ReLU) pada seluruh lapisan konvolusi dan lapisan Dense tersembunyi untuk memperkenalkan non-linearitas ke dalam jaringan, mengatasi masalah vanishing gradient, serta mempercepat proses konvergensi selama pelatihan CNN. ReLU dipilih karena dapat mempertahankan nilai aktivasi positif secara sparsity-friendly sekaligus menekan aktivasi negatif menjadi nol, sehingga membuat propagasi gradien lebih stabil pada arsitektur yang terdiri dari beberapa blok konvolusi bertingkat. Pada lapisan keluaran digunakan fungsi aktivasi softmax yang memetakan nilai logit menjadi distribusi probabilitas terhadap tiga kelas penyakit daun padi, sehingga setiap keluaran dapat ditafsirkan sebagai peluang relatif bahwa citra termasuk kategori *Blight*, *Blast*, atau *Tungro*.

### E. Pelatihan Model

Proses pelatihan CNN dilakukan secara bertahap menggunakan empat skenario jumlah epoch, yaitu 25, 50, 75, dan 100 epoch, untuk menganalisis pengaruh lamanya pelatihan terhadap kemampuan model dalam mengenali pola citra daun padi. Pada setiap skenario, model dilatih dari awal menggunakan data latih dan divalidasi pada data validasi, sementara metrik akurasi dan loss pada kedua subset disimpan melalui objek history untuk dianalisis secara kuantitatif dan divisualisasikan dalam bentuk kurva tren pembelajaran. Setelah proses pelatihan pada masing-masing skenario selesai, model dievaluasi pada data uji guna memperoleh nilai akurasi pengujian sekaligus menghasilkan classification report dan confusion matrix, sehingga performa model dapat dibandingkan secara menyeluruh antar variasi epoch.

### F. Evaluasi Mode

Evaluasi kinerja model dilakukan menggunakan kombinasi metrik akurasi, *precision*, *recall*, dan *F1-score* yang dihitung berdasarkan *confusion matrix* untuk tiga kelas penyakit daun padi pada data uji. Hasil eksperimen menunjukkan bahwa seluruh skenario *epoch* menghasilkan performa yang sangat tinggi, dengan konfigurasi 75 *epoch* memberikan hasil terbaik berupa akurasi pengujian 99,94% dan hanya satu kesalahan klasifikasi dari 1.662 citra, sementara seluruh nilai *precision*, *recall*, dan *F1-score* untuk masing-masing kelas mencapai 1,00. Selain itu, analisis kurva akurasi dan loss pada data latih serta validasi mengindikasikan bahwa model tidak mengalami *overfitting* yang signifikan, karena kedua kurva bergerak konsisten dan konvergen pada nilai yang sangat baik di sekitar epoch optimal

## III. HASIL DAN PEMBAHASAN

### A. Hasil Pelatihan Model

Hasil penelitian yang didapatkan dari tahap training dan testing klasifikasi penyakit daun padi menggunakan convolutional neural network ini menggunakan layer konvolusi (Conv2D), layer pooling (MaxPooling2D), layer flatten (Flatten), serta layer dense (Dense). Fungsi aktivasi (activation) yang digunakan yaitu ReLu. Ukuran kernel/filter yang digunakan untuk setiap layer konvolusi yaitu sebesar  $3 \times 3$ . Sedangkan ukuran pooling yang digunakan yaitu sebesar  $2 \times 2$ . Sedangkan jumlah filter/kernel yang digunakan juga variatif, yaitu 32 filter untuk layer konvolusi 1, 64 filter untuk layer konvolusi 2, 128 filter untuk layer konvolusi 3, dan 256 filter untuk layer

konvolusi 4. Jumlah parameter yang dilatih dalam model ini sebanyak 499,011 parameter. Proses training ditentukan dari banyaknya epoch yang digunakan, dalam penelitian ini menggunakan 25, 50, 75, dan 100 epoch. Proses training akan berhenti jika sudah memenuhi kondisi tersebut. Hasil dari model ditunjukkan pada gambar 2.5.

Fungsi create\_model() siap.  
Model: "sequential"

| Layer (type)                   | Output Shape         | Param # |
|--------------------------------|----------------------|---------|
| conv2d (Conv2D)                | (None, 222, 222, 32) | 896     |
| max_pooling2d (MaxPooling2D)   | (None, 111, 111, 32) | 0       |
| conv2d_1 (Conv2D)              | (None, 109, 109, 64) | 18,496  |
| max_pooling2d_1 (MaxPooling2D) | (None, 54, 54, 64)   | 0       |
| conv2d_2 (Conv2D)              | (None, 52, 52, 128)  | 73,856  |
| max_pooling2d_2 (MaxPooling2D) | (None, 26, 26, 128)  | 0       |
| conv2d_3 (Conv2D)              | (None, 24, 24, 256)  | 295,168 |
| max_pooling2d_3 (MaxPooling2D) | (None, 12, 12, 256)  | 0       |
| flatten (Flatten)              | (None, 36864)        | 0       |
| dense (Dense)                  | (None, 3)            | 110,595 |

Total params: 499,011 (1.90 MB)  
Trainable params: 499,011 (1.90 MB)  
Non-trainable params: 0 (0.00 B)

Gambar 3.1. Hasil Perancangan Model

B. Hasil Eksperimen Performa Model


Model CNN dilatih menggunakan empat variasi epoch yaitu 25, 50, 75, dan 100 untuk mengevaluasi pengaruh jumlah epoch terhadap performa prediksi model. Evaluasi dilakukan dengan pelatihan menggunakan metrik akurasi, loss, precision, recall, dan F1-score di setiap epoch guna menilai kemampuan model dalam mengenali pola citra daun padi.

Tabel 3.1. Hasil Pelatihan Model di Setiap Epoch

| Epoch | Akurasi Training | Loss Training | Akurasi Validasi | Loss Validasi |
|-------|------------------|---------------|------------------|---------------|
| 25    | 99.56%           | 0.0109        | 99.33%           | 0.0162        |
| 50    | 100%             | 0.0002        | 99.94%           | 0.0012        |
| 75    | 100%             | 0.0002        | 100%             | 0.0005        |
| 100   | 100%             | 0.0002        | 100%             | 0.0002        |


1. Hasil Epoch 25

Berdasarkan model yang terbentuk dengan menggunakan epoch 25, dapat diketahui bahwa hasil yang ditunjukkan terhadap data training dan validation yang digunakan.



3.2. Gambar epoch 25

Gambar 2.6 Akurasi Epoch 25 tersebut memperlihatkan kondisi kurva akurasi model. Pada epoch terakhir yaitu epoch 25 diperoleh nilai accuracy 0,9956 dan val\_accuracy 0.993. Kemudian proses testing model menggunakan confusion matrix




Gambar 3.3. Visualisasi Pelatihan 25 Epoch

Berdasarkan Gambar.3.3 Confusion Matrix Epoch 25. Dapat dilakukan perhitungan untuk menentukan akurasi klasifikasi penyakit daun padi. Dengan hasil sebagai berikut. Hasil yang didapat pada pengujian model epoch 25 menggunakan confusion matrix dalam mengklasifikasikan penyakit daun padi menghasilkan nilai akurasi sebesar 99%.

2. Hasil Epoch 50

Berdasarkan model yang terbentuk dengan menggunakan epoch 50, dapat diketahui bahwa hasil yang ditunjukkan terhadap data training dan validation yang digunakan.



Gambar 3.4. Visualisasi Pelatihan 50 Epoch

Pada gambar 3.4 epoch 50 ditampilkan nilai accuracy dan loss untuk data latih serta nilai validation accuracy dan validation loss untuk data validasi. Namun, terjadi ketidakstabilan nilai akurasi di epoch selanjutnya. Hal ini menunjukkan bahwa model mampu berhasil mempelajari dan mengenali pola dengan baik meskipun masih tidak stabil. Pada akhir epoch ke-50, nilai akurasi mencapai akurasi 100% dan validation accuracy mencapai nilai 99% yang menunjukkan bahwa model mampu mengenali pola citra daun padi dengan ketepatan hampir akurat. Selain itu, nilai akurasi dan loss yang stabil di akhir pelatihan menandakan bahwa performa model sudah optimal dan tidak overfitting dengan waktu total yang dibutuhkan adalah 1.108,92 detik untuk menyelesaikan proses pelatihan selama 50 epoch. sehingga proses testing model menggunakan confusion matrix.

Mengevaluasi pada data test...  
 Test Accuracy: 99.88%  
 52/52 ————— 5s 86ms/step

```

--- Classification Report (Epoch 50) ---

```


|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| blast        | 1.00      | 1.00   | 1.00     | 560     |
| blight       | 1.00      | 1.00   | 1.00     | 550     |
| tungro       | 1.00      | 1.00   | 1.00     | 552     |
| accuracy     |           |        | 1.00     | 1662    |
| macro avg    | 1.00      | 1.00   | 1.00     | 1662    |
| weighted avg | 1.00      | 1.00   | 1.00     | 1662    |

**Gambar 3.5 Akhir Pelatihan Model 25 Epoch**

Pada pelatihan 50 epoch. Pengujian akurasi yang dilakukan pada model menggunakan *test dataset* (data uji) yaitu 99.8% yang terdiri dari 1662 gambar. Selain itu, nilai precision, recall, dan f1-score untuk tiga kelas penyakit daun padi mencapai 1.00 secara keseluruhan. Hal ini berarti model dapat mengenali dan mengklasifikasi setiap jenis penyakit daun padi dengan sangat baik optimal.

### 3. Hasil Epoch 75

Berdasarkan model yang terbentuk dengan menggunakan epoch 75, dapat diketahui bahwa hasil yang ditunjukkan terhadap data training dan validation yang digunakan.



**Gambar 3.6. Visualisasi Pelatihan 75 Epoch**

Pada gambar akhirnya konvergen pada nilai mendekati 1.0 (100%). Sementara, pada grafik *Model Loss* (kanan). Kurva *loss* pelatihan (*Training Loss*) dan *loss* validasi (*Validation Loss*) sama-sama mengalami penurunan tajam di awal pelatihan dan secara konsisten bergerak beriringan, mendekati nilai 0.0. Melalui grafik tersebut, dengan ini mengatasi permasalahan class imbalance dan memperluas variasi visual untuk pembelajaran model. Kemudian proses testing model menggunakan confusion matrix

Mengevaluasi pada data test...  
 Test Accuracy: 99.94%  
 52/52 ————— 5s 79ms/step

```

--- Classification Report (Epoch 75) ---

```

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| blast        | 1.00      | 1.00   | 1.00     | 560     |
| blight       | 1.00      | 1.00   | 1.00     | 550     |
| tungro       | 1.00      | 1.00   | 1.00     | 552     |
| accuracy     |           |        | 1.00     | 1662    |
| macro avg    | 1.00      | 1.00   | 1.00     | 1662    |
| weighted avg | 1.00      | 1.00   | 1.00     | 1662    |

**Gambar 3.7. Visualisasi Pelatihan 75 Epoch**

Pada gambar 3.7 setelah proses pelatihan selesai, model dievaluasi kinerjanya menggunakan *test dataset* (data uji) yang


terdiri dari 1662 gambar. Pada tahap pengujian ini, model berhasil mencapai akurasi pengujian (*Test Accuracy*) sebesar 99.94%.

Analisis lebih rinci dilakukan dengan menggunakan *Classification Report* yang menunjukkan bahwa model memiliki performa yang sempurna untuk ketiga kelas. Nilai *Precision*, *Recall*, dan *F1-Score* untuk setiap kelas, yaitu *blast*, *blight*, dan *tungro*, seluruhnya mencapai 1.00. Hasil ini mengindikasikan bahwa model memiliki kemampuan yang sangat tinggi baik dalam memprediksi kelas secara tepat (presisi) dan dapat menemukan semua sampel dari kelas tersebut (*recall*).

Berdasarkan hasil Visualisasi *Confusion Matrix* model berhasil memprediksi 559 gambar *blast* dengan benar, 550 gambar *blight* dengan benar, dan 552 gambar *tungro* dengan benar. Tercatat hanya ada satu kesalahan klasifikasi dari total 1662 data uji, di mana satu gambar yang seharusnya *blast* salah diprediksi oleh model sebagai *tungro*. Dapat disimpulkan bahwa model memiliki kemampuan generalisasi yang sangat baik dengan hasil akurasi 99.94% dan hanya satu kesalahan prediksi.

### 4. Hasil Epoch 100

Berdasarkan model yang terbentuk dengan menggunakan epoch 100, dapat diketahui bahwa hasil yang ditunjukkan terhadap data training dan validation yang digunakan. Hasil ini mengindikasikan bahwa model telah mencapai performa yang sangat tinggi pada data latih dan validasi, namun kemungkinan besar model mengalami *overfitting*, karena tingkat akurasi yang terlalu sempurna dapat menandakan bahwa model terlalu menyesuaikan diri dengan data pelatihan.



**Gambar 3.8. Visualisasi Pelatihan 100 Epoch**

Gambar 4.15 menunjukkan grafik model akurasi dan model *loss* untuk pelatihan model CNN selama 100 epoch. Pada grafik model akurasi, terlihat bahwa nilai training accuracy dan validation accuracy meningkat dengan cepat hingga mencapai nilai maksimum mendekati 1.00 (100%). Hal ini menunjukkan bahwa model mampu mempelajari pola pada citra daun padi dengan sangat baik. Grafik model *loss* menunjukkan tren penurunan pada training loss dan validation loss yang konsisten hingga mendekati nilai 0.0002 di akhir pelatihan, yang berarti kesalahan prediksi model semakin kecil. dengan hal ini, proses testing model menggunakan confusion matrix.



Mengevaluasi pada data test...  
 Test Accuracy: 99.88%  
 52/52 ————— 4s 75ms/step

--- Classification Report (Epoch 100) ---

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| blast        | 1.00      | 1.00   | 1.00     | 560     |
| blight       | 1.00      | 1.00   | 1.00     | 550     |
| tungro       | 1.00      | 1.00   | 1.00     | 552     |
| accuracy     |           |        | 1.00     | 1662    |
| macro avg    | 1.00      | 1.00   | 1.00     | 1662    |
| weighted avg | 1.00      | 1.00   | 1.00     | 1662    |

**Gambar 3.9. Visualisasi Pelatihan 100 Epoch**

Gambar 3.9. menunjukkan hasil akhir dari pelatihan model CNN pada epoch ke-100. Berdasarkan hasil evaluasi menggunakan test dataset yang terdiri dari 1.662 citra, model memperoleh akurasi pengujian sebesar 99.85%. nilai ini menunjukkan bahwa model memiliki tingkat ketepatan yang sangat tinggi dalam mengklasifikasikan citra daun padi ke dalam tiga kelas penyakit, yaitu *Blight*, *Blast*, *Tungro*. Hasil Classification Report juga memperlihatkan bahwa nilai precision, recall, dan F1-score untuk ketiga kelas penyakit tersebut mencapai 1.00 secara keseluruhan. nilai sempurna ini mengindikasikan bahwa model mampu mengenali dan mengklasifikasikan setiap jenis penyakit daun padi dengan sangat baik tanpa kesalahan prediksi yang berarti.

#### IV. KESIMPULAN

Penelitian ini berhasil merancang dan berhasil mengimplementasikan model Convolutional Neural Network (CNN) untuk klasifikasi penyakit daun padi ke dalam tiga kategori, yaitu Blast, Blight, dan Tungro. Arsitektur model terdiri dari empat lapisan konvolusi (Conv2D) yang diikuti MaxPooling2D, Flatten, dan Dense, dengan total 499.011 parameter trainable. Tahap pra-pemrosesan data, meliputi cropping, resizing, normalisasi, dan augmentasi, meningkatkan kualitas serta keragaman dataset. Jumlah citra meningkat dari 500 menjadi 16.620 citra, tersebar merata di ketiga kelas, sehingga mengatasi permasalahan class imbalance dan memperluas variasi visual untuk pembelajaran model.

Hasil pelatihan menunjukkan bahwa penggunaan 75 epoch memberikan performa optimal, dengan akurasi pelatihan dan validasi mencapai 100% serta akurasi pengujian 99,94%. Nilai loss yang rendah mengindikasikan tingkat kesalahan prediksi minimal, sedangkan precision, recall, dan F1-score mencapai 1,00 untuk seluruh kelas, menunjukkan kemampuan klasifikasi yang sangat baik dan konsisten. Secara keseluruhan, model CNN yang dikembangkan mampu mengidentifikasi penyakit daun padi secara akurat dan efisien, serta berpotensi dikembangkan menjadi alat bantu diagnosis otomatis bagi petani dan peneliti untuk deteksi penyakit tanaman secara cepat dan tepat, mendukung peningkatan produktivitas pertanian.

#### V. KUTIPAN

- [1] S. Suciani, D. Arya Anugra, dan E. Faisal, "Deteksi penyakit daun padi menggunakan deep learning dengan arsitektur CNN," *INTECOMS: Journal of Information Technology and Computer Science*, vol. 8, no. 5, 2025. <https://doi.org/10.31539/9112kc41>.
- [2] M. Khoiruddin, A. Junaidi, and W. A. Saputra, "Klasifikasi Penyakit Daun Padi Menggunakan Convolutional Neural Network," *Journal of Dinda: Data Science, Information Technology, and Data Analytics*, vol. 2, no. 1, Feb. 2022. <https://doi.org/10.20895/dinda.v2i1.341>.
- [3] M. H. Susanto, I. B. Santoso, Suhartono, dan A. F. Karami, "Classification of Rice Diseases Using Leaf Image-Based Convolutional Neural

- Network (CNN)*," *Jurnal Nasional Teknik Elektro dan Teknologi Informasi*, vol. 14, no. 3, Aug. 2025, p. 18791. <https://doi.org/10.22146/nteti.v14i3.18791>.
- [4] JM. Dutta dkk., "Rice Leaf Disease Classification A Comparative Study," *Technologies*, vol. 12, no. 11, 2024.
  - [6] A. Apriani, K. Adi, dan C. E. Widodo, "CNN-Based Identification of Rice Leaf Diseases," *International Journal of Scientific Research in Science and Technology*, 2025. <https://doi.org/10.32628/IJSRST25123120>.
  - [7] M. Abdullah, A. Hussain, S. Qadri, J. Jabeen, I. Hussain, M. Khan, dan H. N. Faried, "Deep Learning-Based Rice Leaf Disease Detection Using Custom CNN Models," *Journal of Computing & Biomedical Informatics*, vol. 9, no. 02, 2025.
  - [8] M. K. Hossen, P. K. Das, dan R. Roy, "Detection and Classification of Rice Leaf Diseases Using OpenCV and Deep Learning," *CURRENT APPLIED SCIENCE AND TECHNOLOGY*, vol. 25, no. 5, 2025. <https://doi.org/10.55003/cast.2025.260191>.
  - [9] A. P. Pranjaya, F. Rizki, R. Kurniawan, dan N. K. Daulay, "Klasifikasi Penyakit Pada Daun Tanaman Padi Berbasis YOLOv5," *OJS DJOURNALS* vol. 4, no. 6, 2024. <https://doi.org/10.30865/klik.v4i6.1916>.